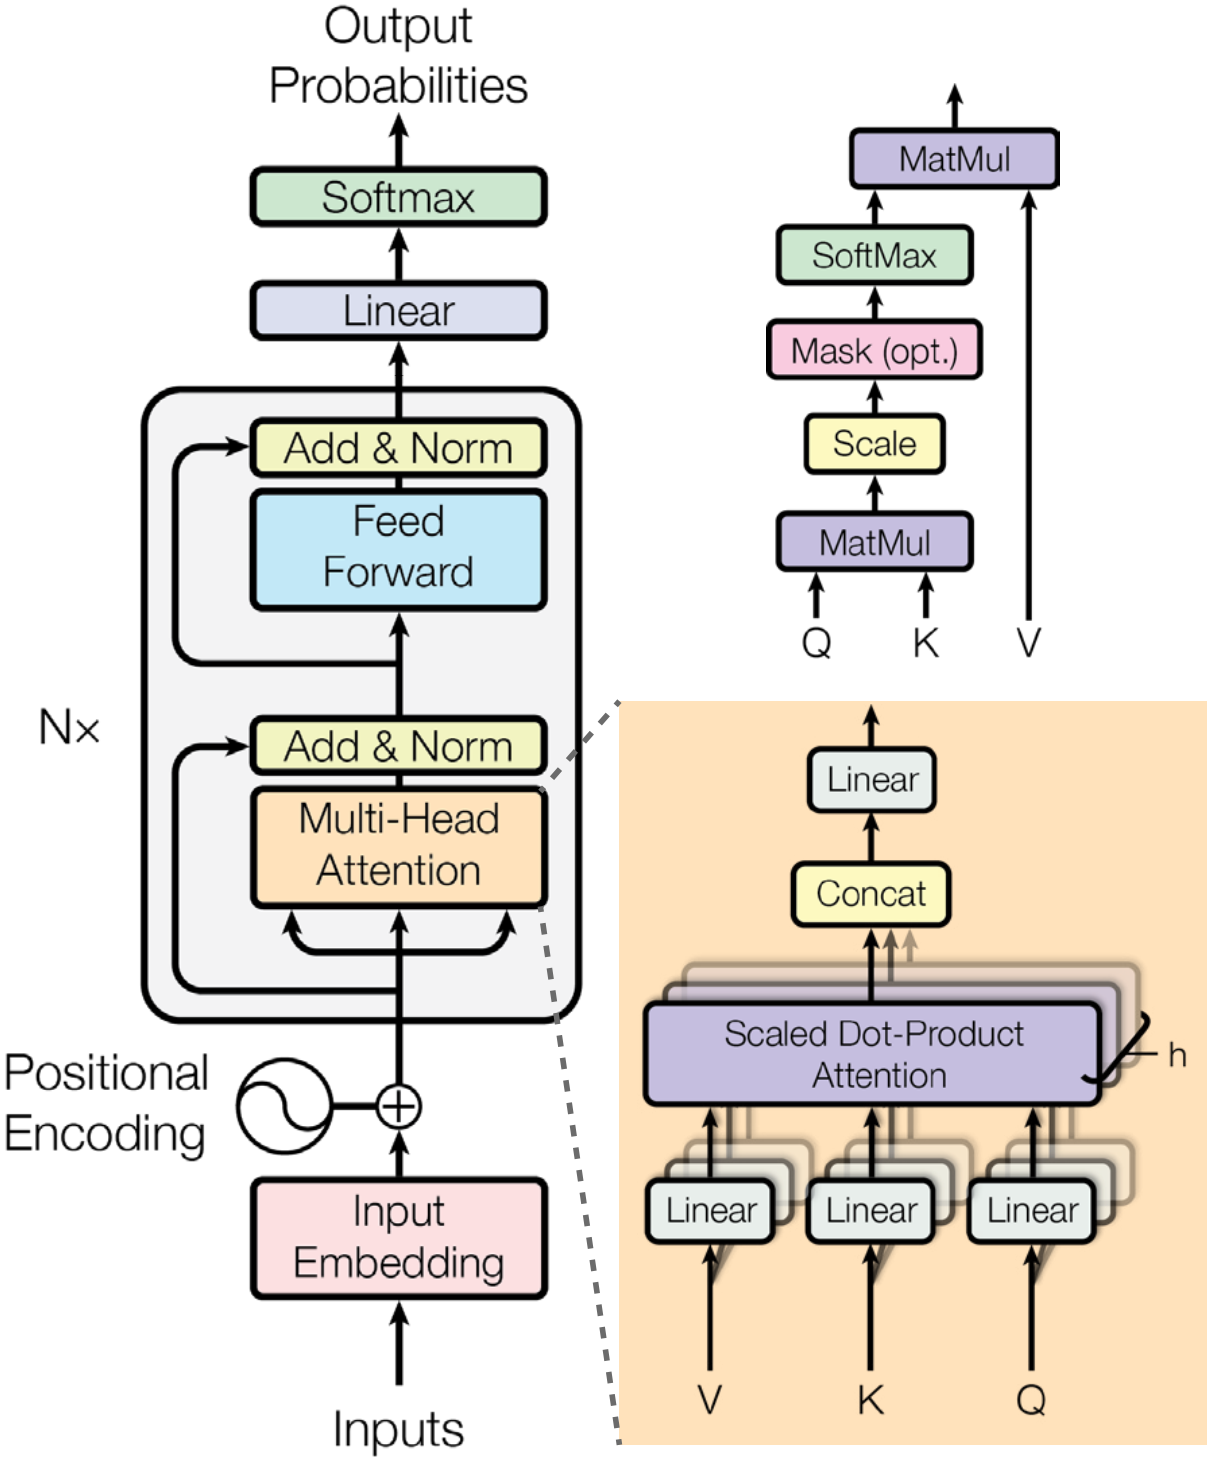
Output Probabilities
Softmax
Linear
Add & Norm
Feed Forward
Nx
Add & Norm
Multi-Head Attention
Positional Encoding
Input Embedding
Inputs
MatMul
SoftMax
Mask (opt.)
Scale
MatMul
Q
K
V
Linear
Concat
Scaled Dot-Product Attention
h
Linear
Linear
Linear
V
K
Q

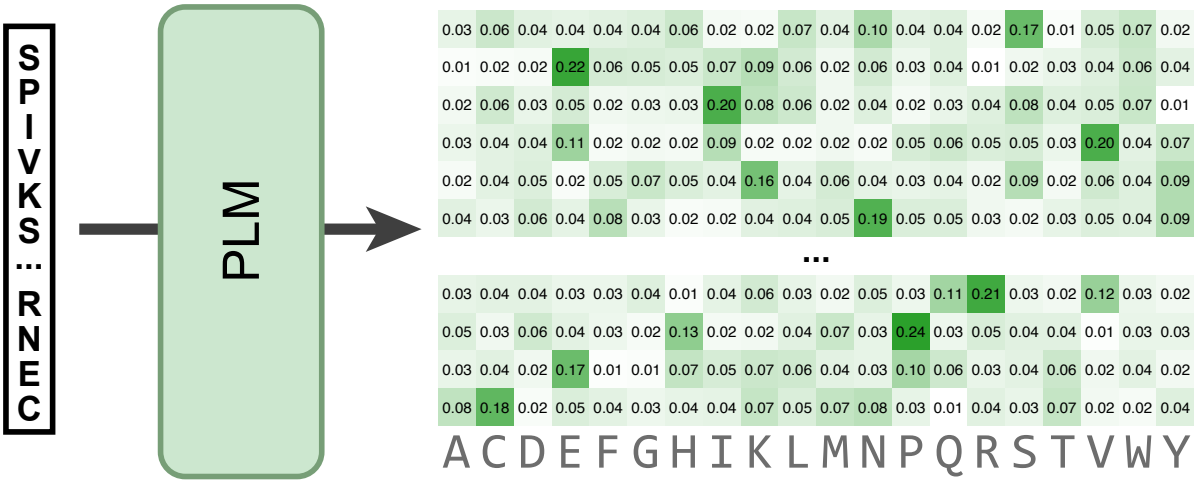
S P I V K S ... R N E C
PLM
0.03 0.06 0.04 0.04 0.04 0.04 0.06 0.02 0.02 0.07 0.04 0.10 0.04 0.04 0.02 0.17 0.01 0.05 0.07 0.02
0.01 0.02 0.02 0.22 0.06 0.05 0.05 0.07 0.09 0.06 0.02 0.06 0.03 0.04 0.01 0.02 0.03 0.04 0.06 0.04
0.02 0.06 0.03 0.05 0.02 0.03 0.03 0.20 0.08 0.06 0.02 0.04 0.02 0.03 0.04 0.08 0.04 0.05 0.07 0.01
0.03 0.04 0.04 0.11 0.02 0.02 0.02 0.09 0.02 0.02 0.02 0.02 0.05 0.06 0.05 0.05 0.03 0.20 0.04 0.07
0.02 0.04 0.05 0.02 0.05 0.07 0.05 0.04 0.16 0.04 0.06 0.04 0.03 0.04 0.02 0.09 0.02 0.06 0.04 0.09
0.04 0.03 0.06 0.04 0.08 0.03 0.02 0.02 0.04 0.04 0.05 0.19 0.05 0.05 0.03 0.02 0.03 0.05 0.04 0.09
...
0.03 0.04 0.04 0.03 0.03 0.04 0.01 0.04 0.06 0.03 0.02 0.05 0.03 0.11 0.21 0.03 0.02 0.12 0.03 0.02
0.05 0.03 0.06 0.04 0.03 0.02 0.13 0.02 0.02 0.04 0.07 0.03 0.24 0.03 0.05 0.04 0.04 0.01 0.03 0.03
0.03 0.04 0.02 0.17 0.01 0.01 0.07 0.05 0.07 0.06 0.04 0.03 0.10 0.06 0.03 0.04 0.06 0.02 0.04 0.02
0.08 0.18 0.02 0.05 0.04 0.03 0.04 0.04 0.07 0.05 0.07 0.08 0.03 0.01 0.04 0.03 0.07 0.02 0.02 0.04
A C D E F G H I K L M N P Q R S T V W Y